

时间序列因果发现方法研读报告

李春阳

东北大学计算机科学与工程系

2025 年 12 月 31 日

摘要

如果能对并行时序数据做到自动化因果发现，量化领域就能不用再靠人工去找策略因子了。但由于时序数据固有的模糊性与难获得性，找到一种高效的因果发现方法就成了迫切的工作。为此我阅读总结了时间序列因果发现的两种深度学习方法——STIC (Short-Term Invariance-based Convolutional) 和 ACD (Amortized Causal Discovery)。STIC 通过利用短时因果不变性原理和卷积神经网络，有效解决了小样本时间序列因果发现的挑战；ACD 则通过摊销式学习框架，实现了在多样本异构图场景下的知识共享与泛化。本文系统分析了两种方法的理论基础、创新设计和实验表现，并在另一项大作业中将其核心思想应用于经济领域时序数据的因果关系分析。通过设计局部因果扫描器、事件分析模块和机制转换检测器等工具，成功识别了不同经济事件期间（如疫情、加息、复苏）因果结构的动态变化。研究结果表明，结合领域知识与先进因果发现方法，能够有效提升小样本、高噪声环境下的因果推断性能。通过阅读前人工作，我深化了对时间序列因果发现理论的理解，也有了粗陋的小项目，未来或许有机会尝试着进行投资实践加以验证。

目录

1	背景及意义	2
1.1	背景	2
1.2	任务	2
1.3	现状分析	3
1.4	挑战和问题	3
1.5	价值和意义	3
2	方法具体描述	4
2.1	流程，整体框架	4
2.2	创新	5
2.3	理论，算法	5

3 实验分析与讨论	6
3.1 实验设置, 数据	6
3.2 实验对比结果与分析	6
3.3 结果讨论	8
4 阅读心得	8
4.1 和课堂的哪一部分知识相关	8
4.2 方法的优势和劣势	9
4.3 如何进行改进	9

1 背景及意义

1.1 背景

因果发现作为数据科学的重要分支,旨在从观测数据中揭示变量之间的因果关系,而不仅限于相关性。在宏观经济分析、金融市场预测和医疗健康监测等领域,理解变量间的因果机制对于科学决策至关重要。例如,美联储加息如何影响汇率波动,原油价格变化如何传导至消费者价格指数(CPI),这些都需要准确的因果关系分析。传统方法在处理时间序列数据时往往面临小样本、高噪声、非平稳性等挑战,难以准确捕捉变量间的动态因果关系。近年来,深度学习技术为时间序列因果发现提供了新思路。STIC 和 ACD 两篇论文,分别从短时不变性卷积网络和摊销式因果发现的角度,为我们理解复杂时序数据中的因果结构提供了新工具。在本次课程项目中,我尝试将这些前沿方法的思想应用到宏观经济指标的因果分析中,探索不同经济事件期间因果关系的变化规律。

1.2 任务

考虑到本课程整体偏 CV,其他模态的数据关注不足,为求新意这里选到对时序数据做分析。所谓时间序列因果发现任务旨在从观测到的多元时间序列数据中推断变量之间的因果关系,包括同时性因果和时滞性因果。具体而言,我们需要解决两个核心问题:(1) 识别哪些变量对之间存在因果关系;(2) 确定因果关系的时滞长度和方向。在宏观经济分析场景中,这一任务特别具有挑战性:首先,我们通常只能获取有限历史数据(如 10 年月度数据,仅 120 个时间点);其次,不同经济时期(如疫情、加息、复苏)可能呈现不同的因果结构,但共享相似的经济机制;第三,宏观经济数据往往包含噪声且可能存在未观测到的混杂变量(如市场情绪、政策预期)。STIC 方法专注于解决小样本场景下的因果发现,其短窗卷积思想即是项目中实现的局部因果扫描器(LocalCausalScanner)设计理念;而 ACD 则致力于利用多个经济事件期间共享的经济机制,提高因果发现性能。

1.3 现状分析

当前时间序列因果发现方法主要分为三类：约束性方法、评分性方法和格兰杰因果方法。

约束性方法（如 PCMCI、PCMCI+）依赖条件独立性测试推断因果关系，但在小样本（如 120 个时间点）情况下统计显著性难以保证，且对高斯噪声等假设依赖较强。这些方法在我们的宏观经济数据上表现不稳定，特别是在不同经济阶段的过渡期。

评分性方法（如 DYNOTEARS）将因果发现视为带约束的优化问题，通过评分函数评估因果图。然而，对无环性约束的过度依赖可能导致次优解，且在高维变量情况下计算复杂度高。我在项目中尝试使用这类方法分析 15 个宏观经济指标，发现其在小样本下容易过拟合。

格兰杰因果方法（如 TCDF、CUTS）利用自回归模型评估变量间的预测关系。传统线性格兰杰方法无法捕捉非线性关系；而深度学习增强的格兰杰方法（如 TCDF）在有限观测时间步下精度较低。在我的项目中，简单的格兰杰检验在分析“美国国债收益率 $\rightarrow$ 人民币汇率”这一关系时，未能捕捉到 2022 年加息期间的强因果效应。

1.4 挑战和问题

在宏观经济时序因果发现中，我们遇到了几个具体挑战，与论文中讨论的问题高度相关：

- 小样本问题：**月度宏观经济数据通常只有 10-15 年（120-180 个时间点），远低于深度学习模型通常需要的样本量。传统方法在这种条件下难以准确识别因果关系，尤其是在捕捉短期经济冲击（如疫情）的影响时。
- 机制变化问题：**不同经济时期（如疫情、加息、复苏）可能呈现不同的因果结构。例如，在 2020 年疫情期间，VIX 恐慌指数与原油价格的关系与正常时期显著不同。现有方法通常假设因果结构恒定，无法适应这种变化。
- 弱信号检测挑战：**某些因果关系（如货币供应量 $M2 \rightarrow CPI$ ）信号较弱，被噪声掩盖。在课程项目中，我实现了一个弱信号因果探测器，结合 Ridge 回归和 Spearman 秩相关，专门解决这类问题。
- 隐藏混杂变量：**宏观经济系统中存在许多未观测变量（如市场情绪、政策预期），可能造成虚假因果关系。例如，当美联储预期加息时，国债收益率和汇率可能同步变动，看似存在直接因果关系，实则受共同隐藏因素影响。

1.5 价值和意义

STIC 和 ACD 两篇论文为上述挑战提供了创新解决方案，具有重要的理论和实践价值：

在理论层面，STIC 首次严格论证了卷积与时间序列生成机制的等价性，为卷积神经网络在因果发现中的应用提供了理论基础；ACD 则开创了摊销式因果发现新范式，将因果图预测与动力学建模分离，为跨样本知识共享提供了理论框架。

在应用层面，这些方法能够显著提高小样本场景下的因果发现精度，处理多样本异构图情况，增强对噪声和隐藏混杂的鲁棒性。在我的经济数据分析项目中，受 ACD 启发实现的事件分析模块 (EventAnalyzer)，成功识别出在“加息”事件期间，美国国债收益率对人民币汇率的因果效应显著增强，而在“复苏”期间，原油价格对 CPI 的传导效应更为明显。这些发现为经济政策制定提供了数据支持。

此外，STIC 和 ACD 的研究推动了因果推断与深度学习的融合，为构建具有因果推理能力的人工智能系统奠定了基础。在当今大数据时代，理解变量间的因果关系而非仅仅是相关性，对于构建可信、可解释的 AI 系统至关重要。这些方法不仅适用于宏观经济分析，还可扩展到金融风险预警、医疗健康监测等多个领域。

2 方法具体描述

2.1 流程，整体框架

STIC (Short-Term Invariance-based Convolutional causal discovery) 和 ACD (Amortized Causal Discovery) 代表了时间序列因果发现的两种不同但互补的方法论，可以看作 CV 和 GNN 在这个领域分别的思想延申。




图 1: STIC 的基本框架

STIC 框架基于短时因果不变性原理，将因果发现转化为端到端的自回归预测问题。其核心流程与 LocalCausalScanner 类实现流程类似：首先，通过滑动窗口将原始时间序列 $X \in \mathbb{R}^{d \times T}$ 转换为窗表示 $W \in \mathbb{R}^{d \times \tilde{\tau} \times c}$ ，其中 $\tilde{\tau}$ 为窗口长度， $c = T - \tilde{\tau}$ 为窗口数量。这种设计有效解决了小样本问题，项目中设置 `window=24` (2 年月度数据) 进行局部因果扫描就是源自于此。其次，STIC 设计双并行模块：时序不变性块使用共享卷积核提取因果结构，机

制不变性块学习转换函数。最后，通过 Hadamard 积和列求和操作预测下一时间步。这种设计充分利用了短时间内因果结构与机制的稳定性，有效提升了小样本下的因果发现能力。

ACD 框架则创新性地将因果图预测与动力学建模分离，采用变分自编码器架构实现跨样本知识共享。其核心流程包含：(1) 编码器 $q_\phi(z|x)$ ：使用图神经网络处理全连接图，预测因果边类型；(2) 解码器 $p_\theta(x|z)$ ：在预测的因果图约束下，通过消息传递机制模拟系统动力学。这一设计启发了我对 **EventAnalyzer** 类的实现：在分析“疫情”、“加息”、“复苏”等不同经济事件时，这些事件背后有不同的因果结构（如疫情期 VIX 与原油关系增强），但共享相同的经济动力学（如供需基本规律）。ACD 的三种推理模式（纯编码器预测、测试时适应、两者结合）类似于对不同经济事件采用不同分析策略的方式，特别是在“弱信号因果探测器”中采用 RidgeCV 回归结合 Spearman 秩相关的方法，正是为了适应小样本高噪声环境。

2.2 创新

个人认为这两篇文章创新思路还是挺自然合理的：

STIC 的创新体现在三方面：首先，它形式化定义了**短时因果不变性**，包括短时时序不变性（因果结构在短期内保持稳定）和短时机制不变性（条件概率分布短期内不变）。为此设置窗口大小需要仔细调整。窗口不能太短（不足以捕捉因果效应），也不能太长（可能跨越不同经济机制时期）。其次，STIC 证明了**卷积与时序生成机制的等价性**，为使用 CNN 进行因果发现提供了理论基础。这启发他人尝试将时间序列数据转换为二维表示，应用计算机视觉中的技术进行因果特征提取。第三，STIC 提出**窗因果矩阵**，统一表示同时性和时滞性因果关系，在具体实现中可以用 spmm 的优化方法，当然这就不算理论内容了，这里不赘述。

ACD 的创新主要体现在四方面：首先，开创了**摊销式因果发现新范式**，将因果图预测与动力学建模分离，将不同经济事件视为具有不同因果图但共享经济机制的样本。其次，ACD 设计了**可泛化的因果图预测器**，使单一训练好的模型能够预测未见过样本的因果图，识别高波动期（ $VIX > 25$ 或利率突变），在这些时期应用专门训练的因果模型。第三，ACD 提出**测试时适应机制**，在极小样本情况下也能获得准确因果图。最后，ACD 通过扩展编码器预测隐变量，有效缓解了噪声和未观测变量的影响，通过分析残差序列来检测未观测到的经济因素。

2.3 理论，算法

STIC 的理论基础来自信号处理和因果不变性理论。论文证明在加性噪声模型下，时间序列数据生成过程等价于空间域和时间域卷积操作，而在短期窗口内，经济指标之间的因果关系相对稳定。算法上，STIC 通过优化 MSE 损失训练模型，采用了类似的自回归框架，但用偏相关系数检验替代了端到端训练，以适应小样本限制。具体来说，对于每对变量 (src, tgt) 和滞后 lag，构建回归模型： $tgt(t) = \beta_0 + \beta_1 tgt(t-1) + \beta_2 src(t-lag) + \epsilon$ ，其中 β_2 的显著性和大小决定了因果强度。这一设计受到了 STIC 中机制不变性块的启发，但

有所简化。

ACD 的理论基础建立在 Granger 因果和变分推断之上。论文证明当编码器预测“无边”类型时，解码器使用零函数，确保变量 i 不 Granger-cause 变量 j 。这一理论为我的 EventAnalyzer 类提供了依据：在分析特定经济事件时，只有当一个指标的历史值对预测另一指标当前值有显著贡献时，才认为存在因果关系。算法上，ACD 优化证据下界 (ELBO)。在我的项目中无法实现完整的变分框架，但借鉴了其核心思想：首先识别高波动经济状态 (机制 1)，然后在这些状态下检验变量间的强相关性，这类似于 ACD 中编码器-解码器的分离设计。对于弱信号检测，我实现了 RidgeCV 回归结合 Spearman 秩相关的方法，这受到了 ACD 处理噪声和非线性的启发，但采用了更适合小样本的简化版本。

3 实验分析与讨论

3.1 实验设置，数据

两项研究均在合成数据集和真实世界基准数据集上进行了全面评估。STIC 在四个数据集上进行验证：(1) 线性高斯数据集，变量间关系为线性，噪声服从标准正态分布；(2) 非线性高斯数据集，变量间关系为余弦函数，噪声为高斯分布；(3) 线性均匀噪声数据集，变量间关系为线性，但噪声服从均匀分布；(4) FMRI 基准数据集，包含 28 个不同的大脑网络，每网络观测 200 个时间步。ACD 则在三个数据集上验证：(1) Kuramoto 数据集，模拟五个相位耦合振荡器的一维时间序列；(2) Particles 数据集，模拟五个在二维空间中运动的粒子，某些粒子通过弹簧单向影响其他粒子；(3) Netsim 数据集，模拟 15 个脑区之间的功能磁共振成像数据。

实验评估采用不同的对比方法和指标。STIC 与六种当下的常见方法对比：约束性方法 (PCMCI, PCMCI+)、评分性方法 (DYNOTEARS) 和格兰杰因果方法 (TCDF, CUTS, CUTS+)，使用 F1 分数和精确率作为评估指标。ACD 则与深度学习方法 (NGC, eSRU) 和传统方法 (Transfer Entropy, Mutual Information, Linear Granger) 对比，主要使用 AUROC 指标。两个研究均探讨了方法在不同变量数量、观测时间步长、噪声水平和隐藏混杂变量情况下的表现，并进行了消融实验分析关键超参数的影响，最终在小样本下表现了强鲁棒性与高性能，证明了策略的有效性。

3.2 实验对比结果与分析

STIC 在小样本场景的优势：在具有有限观测时间步 ($T=100$) 的线性高斯数据集上，STIC 的 F1 分数 (0.76) 显著优于其他方法，是 PCMCI+ (0.37) 和 DYNOTEARS (0.37) 的约 2 倍。随着变量数量增加 ($d=5$ 到 20)，STIC 保持稳定的性能 (平均 $F1=0.72$)，而 PCMCI+ 和 DYNOTEARS 的性能下降更为明显。这归因于 STIC 的窗表示技术，通过对单个时间序列进行滑窗转换，实现了有效的样本增广，提升了小样本下的信息利用率。如图所示，当 $T=100$ 时，STIC 的 F1 分数比其他方法高出一倍以上，证明了其有效适应了小样本场景。

非线性关系建模能力：在非线性高斯数据集上，STIC 实现 0.44 的 F1 分数，略高于




图 2: 左图展示了在具有不同变量数量 (d) 和观测时间步数 (T) 的线性高斯数据集上评估得到的 F1 分数结果, 右图则展示了对应的精确率 (precision) 结果。

PCMCI+(0.43) 和 TCDF(0.41)。ACD 在 Kuramoto 非线性相位耦合系统上同样表现出色, AUROC 达到 0.952。两者都证明了深度学习方法在捕获复杂非线性因果关系方面的优势, 特别是 STIC 的机制不变性块和 ACD 的图神经网络编码器, 能够有效建模非线性转换函数。STIC 在非线性数据上的稳定表现验证了其机制不变性块的设计有效性。




图 3: 在粒子数据集 (左图) 和 Kuramoto 数据集 (右图) 上, 因果发现方法的性能表现

噪声鲁棒性对比: ACD 在有噪声场景下表现出色, 即使在观测噪声标准差达到 0.2(约为信号标准差 0.6 的 $1/3$) 的情况下, 仍能在 Particles 和 Kuramoto 数据集上保持 >0.9 的 AUROC (见论文图 4)。STIC 虽未系统测试噪声场景, 但在 FMRI 真实数据 (通常含有大量噪声) 上达到 0.80 的精确率, 证明其实际应用价值。这表明两种方法都能在一定程度上抵抗观测噪声的干扰。

隐藏混杂处理: ACD 专门设计了隐变量扩展来处理隐藏混杂。在隐温度变量实验中, ACD(Latent) 在 $=2$ 时达到 0.90 的 AUROC, 显著优于 Mean(0.78) 和 None(0.64) 基线。在隐藏时间序列实验中, 当 4 个观测变量受隐藏变量影响时, ACD(Latent) 保持 0.94 的 AUROC, 而 Mean 和 None 基线降至 0.85 和 0.83。这些结果 (如论文图 5-6 所示) 证明了 ACD 在处理隐藏混杂方面的有效性。STIC 未专门处理隐藏混杂, 不过感觉某种意义上利用邻域连续性做卷积也可以视为一种除杂滤波的过程。

3.3 结果讨论

两项研究的结果揭示了时间序列因果发现中几个关键见解。首先，**样本效率**和**知识泛化**代表了两种互补的研究方向。STIC 通过内部样本增广解决了单序列小样本问题，而 ACD 通过跨样本知识共享解决了多样本异构图问题。这两种方法在不同场景下各有优势：当面对单个短时间序列（如短期临床监测）时，STIC 更为适用；当拥有多个相关样本（如多患者 fMRI 记录）时，ACD 展现出明显优势。

其次，**表示学习**对因果发现至关重要。STIC 的窗因果矩阵和 ACD 的图表示都超越了传统方法的简单线性模型，能够捕获更复杂的因果机制。特别是，STIC 证明了卷积操作与时序数据生成机制的理论等价性，为深度学习因果发现提供了理论基础；ACD 则证明了分离因果图预测与动力学建模的有效性，实现了零样本因果推断。如 STIC 论文第 2.4 节所示，其理论证明建立了卷积与时间序列数据生成机制间的等价关系，为方法设计提供了坚实基础。

第三，**噪声和隐藏混杂**是实际应用中的主要挑战。ACD 通过隐变量建模有效缓解了这些问题，但 STIC 在此方面仍有提升空间。ACD 论文图 5-6 展示了隐变量扩展在处理隐藏温度和隐藏时间序列方面的有效性，而 STIC 论文的 FMRI 实验表明其在真实噪声数据上仍保持较高性能。这提示未来研究应更关注鲁棒因果发现，尤其是在医学等关键领域，隐藏混杂普遍存在。

最后，两项研究揭示了**因果发现评估**的复杂性。STIC 使用 F1 和精确率，强调边预测的准确性；ACD 使用 AUROC，关注排序质量。这反映了因果发现任务的不同方面：有时需要高精度的少量边（如药物靶点发现），有时需要尽可能完整的因果结构（如系统建模）。STIC 论文表 3 和 ACD 论文表 1-2 的不同评估结果表明，方法性能依赖于评估指标的选择，未来工作应考虑更多样化的评估指标，包括领域特定的效用指标和干预预测准确性。

总体而言，这些实验不仅验证了两种方法的技术优势，更揭示了时间序列因果发现的深层挑战和机遇。随着更多高质量时序数据的出现，这些方法有望在神经科学、气候科学和精准医疗等领域产生实质性影响。论文中展示的性能差距（如 ACD 在 Kuramoto 上 0.952 vs NGC 的 0.574）证明了新方法的显著进步，为因果发现领域树立了新基准。

4 阅读心得

4.1 和课堂的哪一部分知识相关

这两篇都有点交叉领域的意味，特别是卷积神经网络 (CNN) 在 STIC 中的应用，与课堂讨论的 CNN 在图像识别中的工作原理相似，只是输入从二维图像变成了时间序列。ACD 中的 GNN 编码器，也是把别的领域的工具拿来作表示学习。`WeakSignalCausalScanner` 中所使用 RidgeCV 回归，就是深度学习正则化思想的简化版本。

4.2 方法的优势和劣势

通过在宏观经济数据上实现简化版本的这些方法，我对 STIC 和 ACD 的优势和局限有了更深入认识：

STIC 方法的优势在小样本场景下尤为明显。在项目实践中，当分析仅 12 个月的“复苏”事件数据时，STIC 启发的局部扫描方法比全局方法发现了更多合理因果关系。在分析美国国债收益率对汇率的影响时，STIC 的窗表示方法有效捕捉到了 2022 年 3 月开始的持续影响过程。

然而，STIC 也存在明显局限。首先，它的无隐藏混杂假设在宏观经济中常不成立。例如，当美联储暗示加息时，国债收益率和汇率同步变动，看似直接因果，实则受共同隐藏因素（政策预期）影响。其次，需要预设最大时滞，在项目中设置 `max_lag=6`，但难以确定这是否最优。第三，STIC 主要针对单时间序列设计，在分析多经济事件时，无法共享知识，导致重复计算。

ACD 方法的优势体现在其创新框架和鲁棒性设计上。在项目中，ACD 启发的事件分析模块成功识别出不同经济事件期间的因果结构变化，同时共享基础经济机制。其三种推理模式提供了灵活性——在数据充足的“加息”事件使用完整分析，在小样本“复苏”事件使用测试时适应 (TTA)。更重要的是，ACD 通过隐变量扩展处理噪声和隐藏混杂的思想，启发我实现了弱信号和机制转换检测器，在高噪声环境下仍能发现有意义的因果关系。

ACD 的主要局限在于其对几种强假设的依赖，这在经济系统中难以严格验证。方法需要多样本训练，在分析单一经济事件时无法直接应用。计算复杂度高，我的简化版本虽能运行，但完整 ACD 在个人电脑上难以实现。此外，解码器的模型偏差可能传导至图估计，在项目中发现当使用过于复杂的模型时，结果反而不如简单线性模型稳定。

4.3 如何进行改进

基于项目实践和论文研读，我认为以下改进方向值得探索：

简化摊销学习框架：ACD 的完整变分自编码器架构过于复杂，但其核心思想跨样本知识共享可以简化实现。例如，可以先对每个经济事件单独训练简单的因果模型，然后提取这些模型的共有特征（如相同因果方向但不同强度），形成一个基础模型，再针对新事件进行微调。这保持了摊销思想，但计算复杂度大幅降低，也方便去实现。

自适应窗口机制：STIC 使用固定窗口大小，但经济数据的因果稳定性时间尺度可能变化。可以设计自适应窗口机制，例如使用统计检验（如 Chow 检验）自动检测因果结构变化点，动态调整窗口大小。在我的项目中，可以将 `window` 参数从固定 24 改为基于 VIX 波动率的自适应值，提高方法灵活性。

混合因果发现框架：结合 STIC 的短窗高效性和 ACD 的跨样本泛化能力，设计混合框架。例如，在每个短窗口内使用 STIC 风格的卷积分析，同时在不同窗口间共享 ACD 风格的编码器，识别全局不变的因果机制。

因果发现与预测闭环：将因果发现与预测任务结合，形成闭环验证。例如，用发现的因果图指导时间序列预测模型的结构设计，然后通过预测性能反向验证因果图质量。在我

的宏观经济分析中，可以使用识别的因果关系构建预测模型，预测下一季度 CPI，通过预测准确性验证因果图质量。这种实用导向的评估，比纯理论指标更直观。

通过这个项目，我深刻体会到虽然 STIC 和 ACD 这样的前沿论文提供了强大工具，但将其应用到真实问题需要灵活调整、批判思考和跨学科知识。我没钱没卡，可能无法实现最先进模型，但通过理解核心思想并结合领域知识，仍然能做出有意义的贡献。这种“理论指导实践，实践反馈理论”的迭代过程，正是实践的核心价值所在。

参考文献

- [1] Shen, R., Wang, B., Zhao, C., Guan, Y., & Jiang, J. (2024). Causal Discovery from Time-Series Data with Short-Term Invariance-Based Convolutional Neural Networks. *arXiv preprint arXiv:2408.08023*.
- [2] Löwe, S., Madras, D., Zemel, R., & Welling, M. (2022). Amortized Causal Discovery: Learning to Infer Causal Graphs from Time-Series Data. *Proceedings of the Conference on Lifelong Learning Agents (CLear)*.